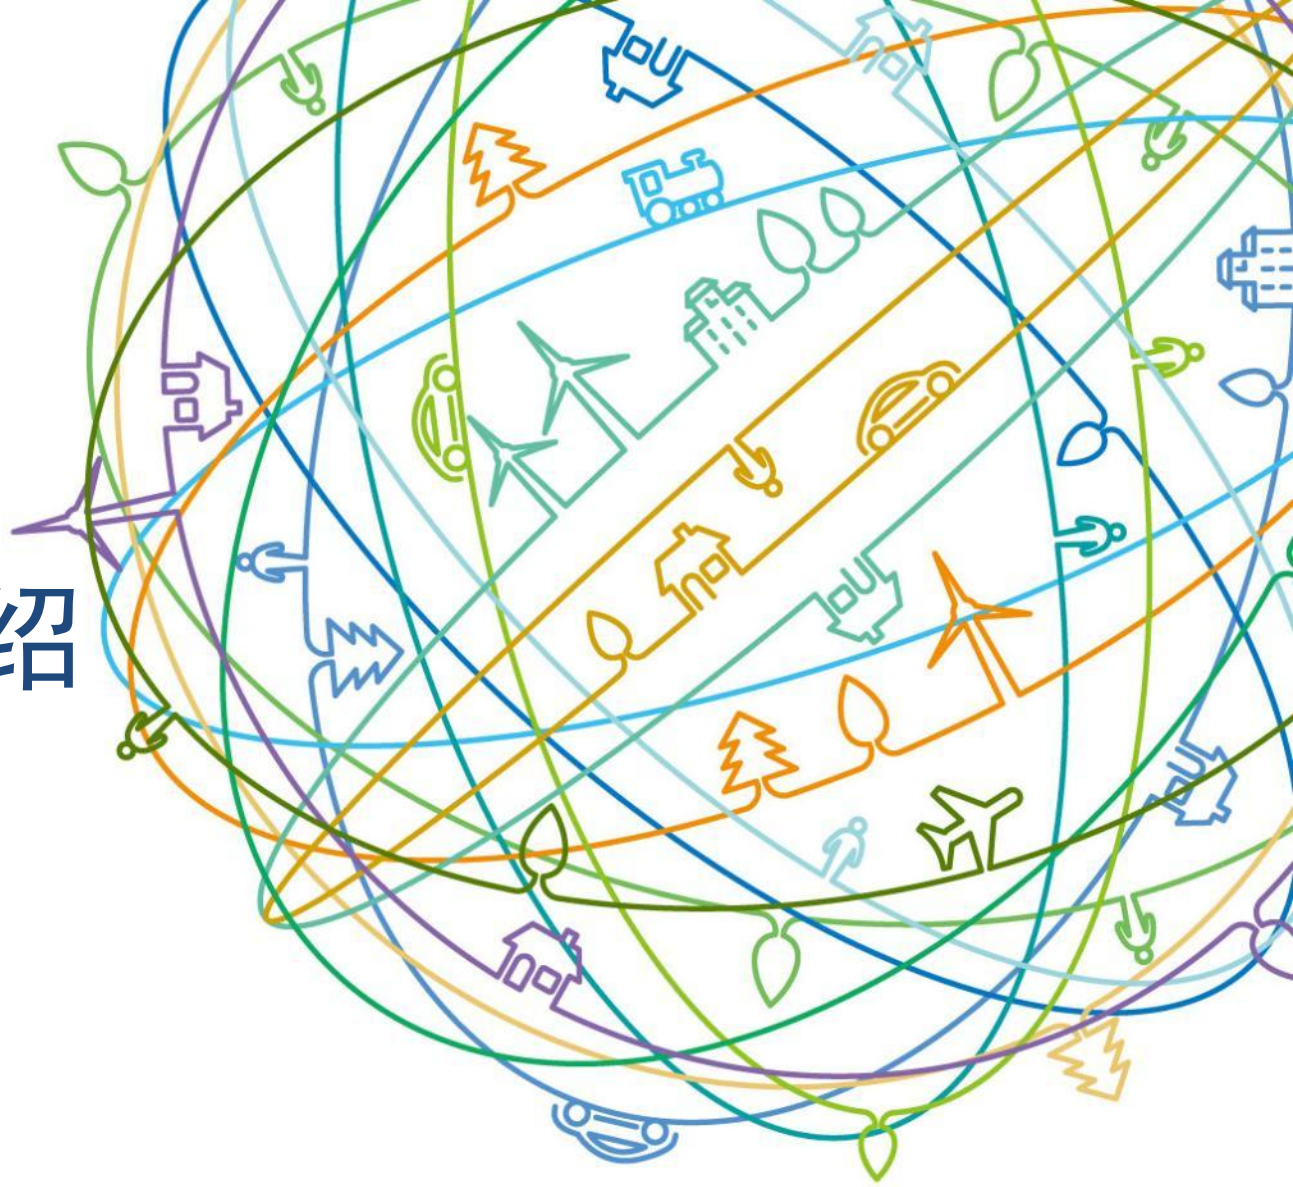
自然语言处理(NLP)介绍



摘要

本次交流分享是一次关于自然语言处理（NLP）的入门性的介绍。而详细的算法和技术放在可能的后续分享和学习中。

本次分享主要分以下几个部分：

- 什么是NLP
- 关于机器学习
- NLP的技术原理
- 深度学习与NLP
- NLP的主要应用
- 参考资源

目 录

01

什么是NLP

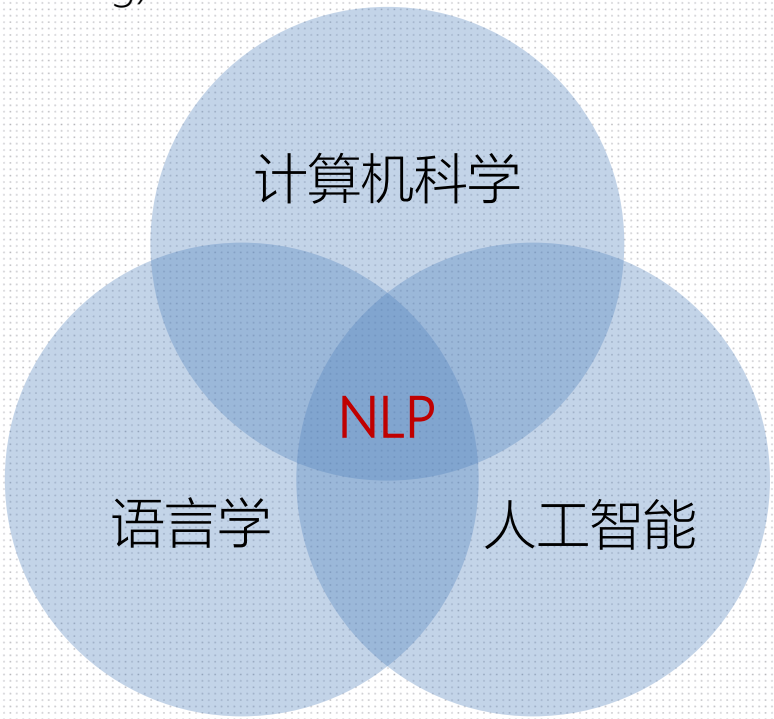
HUAWEI

NLP的基本概念

NLP是一门融合了计算机科学、人工智能以及语言学的交叉学科。

NLP研究如何通过机器学习（ML）等技术，让计算机学会处理人类语言，乃至实现最终目标——理解人类语言或者人工智能。

不同视角：NLP(Natural Language Processing)、CL(Computational Linguistics)，NLU(Natural Languague Understanding)



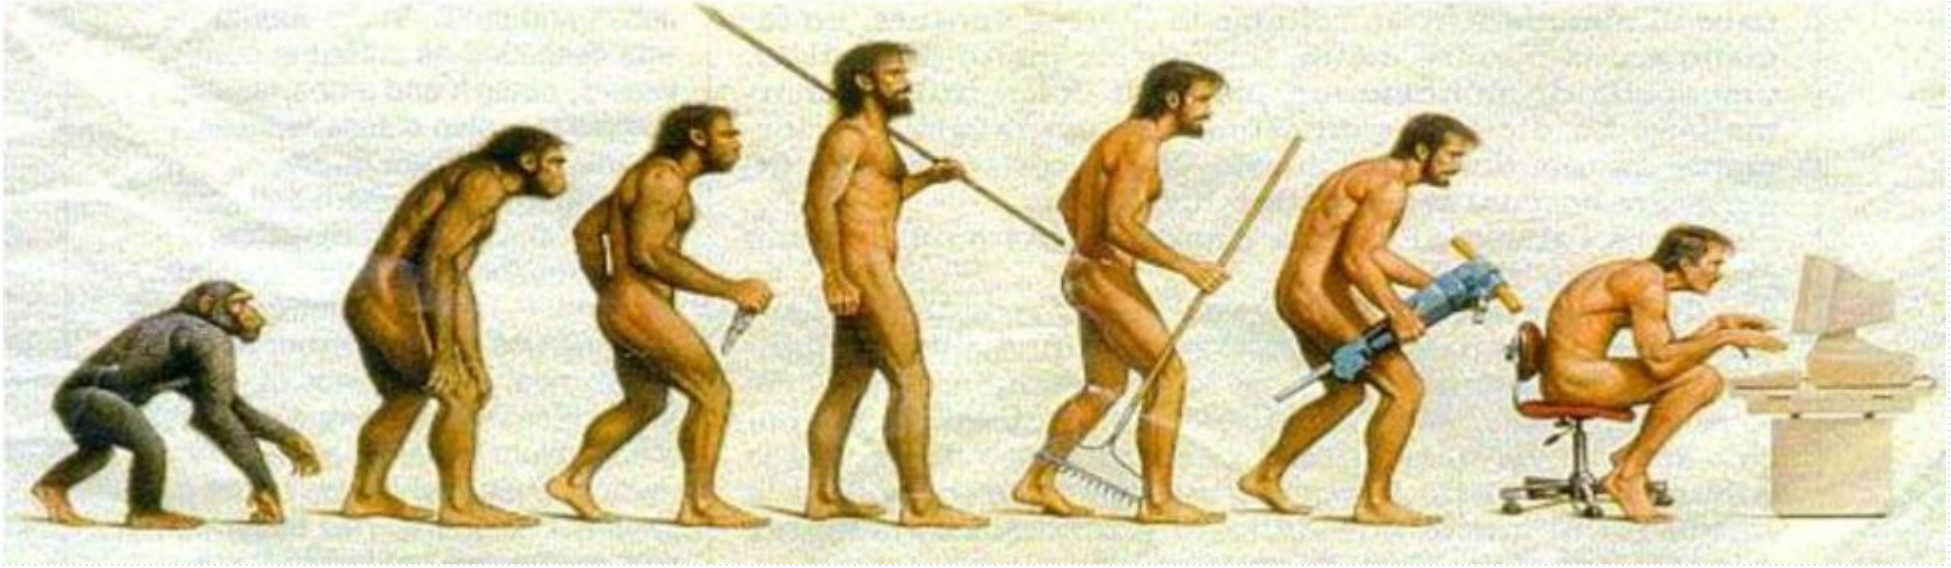
1956，达特茅斯，人工智能夏季研讨会
NLU正式成为人工智能研究的核心课题之一
Dartmouth Conference
Summer Research Project on Artificial Intelligence



Moore、McCarthy、Minsky、Selfridge、Solomonoff
2006

自然语言的复杂性

自然语言是人类社会发展过程中自然产生的语言，是最能体现人类智慧和文明的产物。



自然语言高度灵活，充满不确定性，这对于只能执行几种基本逻辑操作的计算机来说，读懂和理解自然语言就变得极其困难。

我想静静！

我想过过过儿过过的生活

货拉拉拉不拉拉不拉多，取决于货拉拉拉拉不拉多时，拉不拉多拉得多不多

HUAWEI

自然语言的特点



新冠、核酸、健康码、耗子尾汁、干饭人、凡尔赛……

牛津英文：185000
现代汉语常用词表：56008
不断增加……

苹果、粉丝；
bank, interest, transformer ……
那辆白色的车是黑车/ 臭豆腐真香啊！

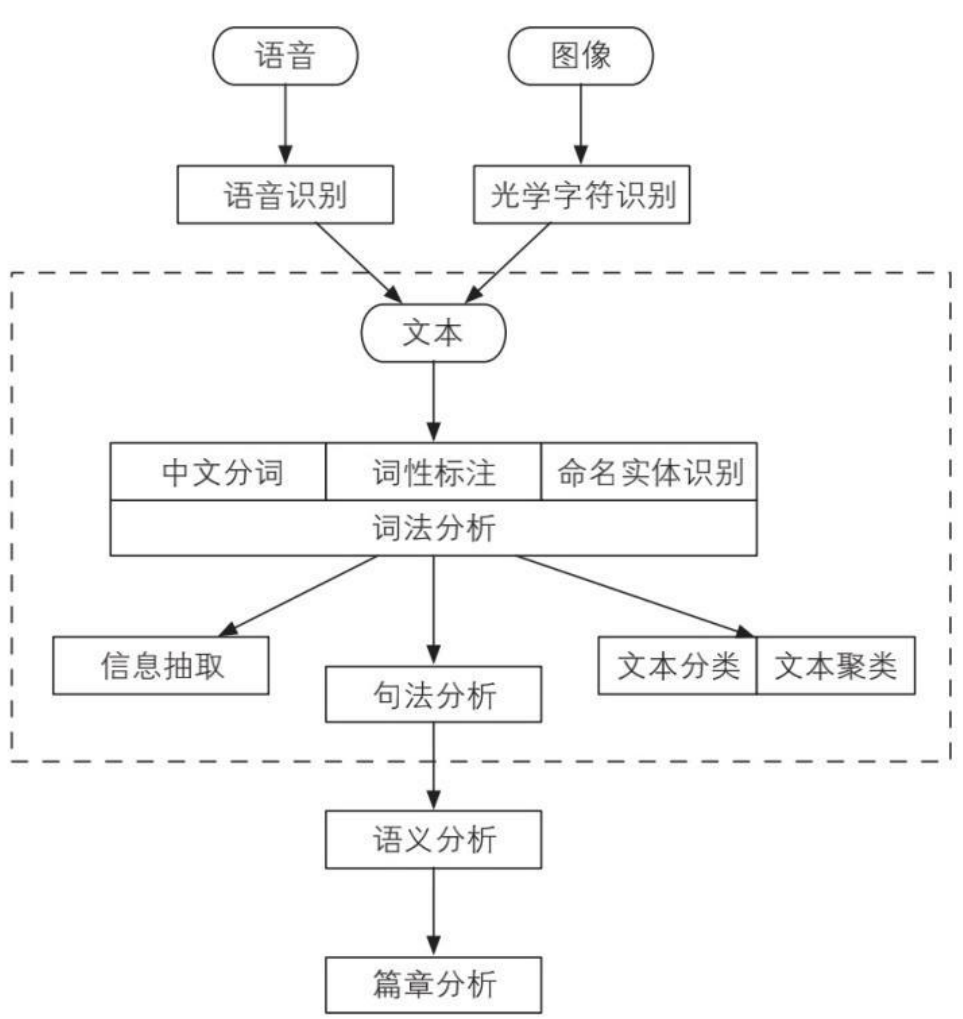
研表究明，汉字的序顺并不定一能影阅响读
Aoccdrnig to the rscheearch, it deosn't mttaer in waht oredr the ltteers in a wrod are, the olny iprmoetnt tihng is taht the frist and lsat ltteer be at the rghit pclae.

喜欢乡下的孩子
喜欢上一个人
他背着老师和班长去了网吧

在微信圈里潜水；
打铁还要自身硬；
你简直是个木头脑袋！
雪域高原处处盛开民族团结之花；

HUAWEI TECHNOLOGIES CO., LTD.
HUAWEI

NLP的到底要做什么?



1. 输入识别
   Speech Recognition & Optical Character Recognition
2. 词法分析
   中文分词：将文本分割为有意义的词语；
   词性标注：确定每个词语的类别和浅层的歧义消除；
   实体识别：识别出专有名词。
3. 信息抽取
   抽取句子中的关键字，识别意图。
4. 文本分类和聚类
   分类：对于文本段进行不同维度的分类预测。
   聚类：相似文本归类聚合或排除重复文本。
5. 句法分析
   分析句子语法，得到句子的主谓宾结构等。
6. 语义分析和篇章分析
   语义分析：词义消岐、语义角色标注、语义依存分析
   篇章分析：解析和提取整篇文章的中心思想等
7. 应用层任务
   自动问答、自动摘要、机器翻译.....

HUAWEI TECHNOLOGIES CO., LTD.
HUAWEI

NLP的历史和流派



1950

基础研究
图灵测试发问“机器能否思考”、乔姆斯基语法、首个基于规则的句法分析器

1980

规则系统
第一个自动问答系统（手写规则）、大量手写规则的“NLU”系统、面向逻辑推理的编程语言

1990

统计学习
统计学习方法的兴起、语料库建设、大量机器学习理论与应用、革命性实用水准

2010

深度学习
神经网络的复兴、表示学习、端到端设计

规则系统

- 理性主义
- 基于符号逻辑
- 规则、词典+算法
- 语言学规则驱动
- 专家经验
- 僵硬、机械、难扩展

统计学习

- 经验主义
- 基于统计学习
- 语料、特征+模型
- 数据驱动
- 大规模训练样本
- 模型限制、算力限制

深度学习

- 连结主义
- 基于神经网络
- 语料+模型
- 数据驱动
- 算力、硬件

HUAWEI

目 录

02

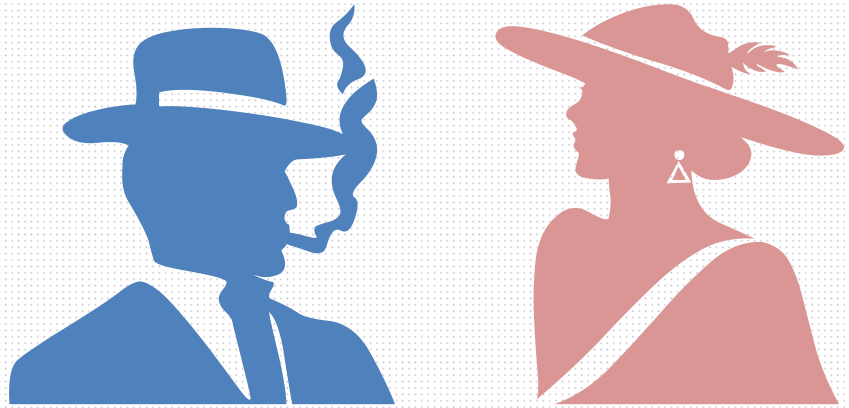
关于机器学习

HUAWEI

什么是机器学习（Machine Learning，ML）

- 不直接编程却能赋予计算机提高能力的方法。——Arthur Samuel（AI先驱之一）
- 计算机通过某项任务的经验数据提高了在该项任务上的能力。——Tom Mitchell（美国工程院院士）
- 机器学习的本质：通过观察到的大量已知事件的状态频率，推断当前事件的最大可能状态。其理论依据：贝叶斯先验概率学派理论。
- 让计算机学会算法的算法
- 机器学习的核心是数学模型

挑战——根据一个中国人的姓名来判断TA的性别。



$$sex = f(name)$$

也就是说我们需要找到一个函数形式，其自变量是姓名，而应变量就是我们需要的结果：性别。

HUAWEI

固定编程 VS 机器学习

- 固定编程：函数的逻辑和参数，是事先经过数学分析，已经确定的。程序只负责按照固定的计算逻辑进行运算和结果输出。
- 机器学习：函数的参数是模糊未知的，通过喂给大量的样本数据（[输入,结果]对）进行训练，由程序自己拟合出匹配的参数，并通过不断迭代，逐步接近最精确的模型。训练后的模型可用于后续正式的预测和处理。

$$y = ax^2 + bx + c$$

```
public double quadratic(double x) {
    double y;
    y = 2 * Math.pow(x, 2) + 3 * x + 4;
    return y;
};
```

VS

```
[-5,39],[-4,24],[-3,13],
[-2,6],[-1,3],[0,4],
[1,7],[2,18],[3,31],
[4,48],[5,69]
......
```

$$sex = f(name)$$

```
public String name2sex(String name) {
    String sex = "不知道";
    if (name.contains("丽") || name.contains("冰") || ...) {
        sex = "女";
    };
    if (name.contains("壮") || name.contains("雁") || ...) {
        sex = "男";
    };
    return sex;
};
```

VS

```
[班尔达,男], [崔云龙,男], [陈萍,女],
[崔巍,男], [陈月会,男], [陈星星,女],
[陈贵香,女], [陈莹,女], [陈娇,女],
[陈婧怡,女], [陈乐,男], [陈华星,男],
[陈哲,男], [陈立,男], [陈佩珊,女],
[丁小燕,女], [段青青,女], [杜雷,男],
[豆翠翠,女], [段临晶,女], [丁恒,男],
[冯林莉,女], [付成军,女], [付东阳,女],
[冯媛媛,男], [付丽,女], [方堃,女],
[谷素琴,女], [古连新,男],……
```


HUAWEI

特征

- 特征是指事物的特点转化的数值。例如：牛：leg（4），wing（0）；鸟：leg（2），wing（1）
- 特征在数学模型中，也可以简单理解为函数的计算逻辑，例如$y = ax^2 + bx + c$的特征就是一个一个二次项，一个一次项，一个常数。
- 中国人名的特征是什么？

姓氏无关

特定性别常用字

（男：壮、雁、健、强……）
（女：丽、艳、冰、雪……）
（中：文、海、宝、玉……）

沈雁冰？

加优先级权重解决？
权重怎么定义？

特征提取

特征序号	特征条件	特征值
1	是否含“雁”	1
2	是否含“冰”	1

二维向量表示：“沈雁冰”$= [1,1]$

特征序号	特征条件	特征值
1	是否含“雁”	1
2	是否含“冰”	1
3	是否含“丽”	0
4	是否含“壮”	0

四维向量表示：“沈雁冰”$= [1,1,0,0]$

特征序号	特征条件
5	是否“雪”字结尾
6	是否“雪”字结尾并且倒数第二字是“吹”

$$f(x) = w_1x_1 + w_2x_2 + b$$

权重表示：$w = [w_1, w_2]$

$$f(x) = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + b$$

权重表示：$w = [w_1, w_2, w_3, w_4]$

这就是特征工程！

HUAWEI TECHNOLOGIES CO., LTD.

HUAWEI

数据集

- 机器学习的目的，就是得到模型的具体参数。
- 很多问题，我们无法直接编写固定的算法（规则）来解决。（我们自己也说不清楚什么样的姓名是男性）。
- 我们可以准备大量的例子（样本），希望机器自动从例子中学习到人名的规律。
- 这些样本的集合，在ML领域被称为数据集，在NLP领域则被称为语料库。

```
[班尔达,男], [崔云龙,男], [陈萍,女],
[崔巍,男], [陈月会,男], [陈星星,女],
[陈贵香,女], [陈莹,女], [陈娇,女],
[陈婧怡,女], [陈乐,男], [陈华星,男],
[陈哲,男], [陈立,男], [陈佩珊,女],
[丁小燕,女], [段青青,女], [杜雷,男],
[豆翠翠,女], [段临晶,女], [丁恒,男],
[冯林莉,女], [付成军,女], [付东阳,女],
[冯媛媛,男], [付丽,女], [方堃,女],
[谷素琴,女], [古连新,男],……
```

```
[CE6851HI是否支持VPLS/VLL,规格查询], [CE12800 ARP规格,规格查询],
[CE6810EI ARP表规格,规格查询], [CE7855EI是否支持堆叠,规格查询],
[WLAN推荐的版本,版本推荐], [S系列和E系列交换机推荐的版本,版本推荐],
[CE系列交换机推荐的版本,版本推荐], [5720默认密码,查询密码],
[防火墙缺省Web用户名和密码,查询密码], [默认Telnet用户名和密码,查询密码],
[请问S5720-52X-PWR-SI-AC的功耗,查询功耗], [s6720的功耗是多少,查询功耗],
[s5700的整机功耗,查询功耗], [S5700典型功耗,查询设备功耗],
[Web网管无法登录,故障处理], [PPPoE拨号方式无法上网,故障处理],
[E1接口对接不能Up,故障处理], [推荐几款园区交换机， 产品推荐],
[给我推荐几款FCoE交换机,产品推荐],……
```

ML领域常用的公开数据集

数据集	任务	规模	授权
MNIST	手写数字识别	6w训练样本，1w测试样本	CC BY-SA 3.0
ImageNet	图像识别	140w手工标注物体和边框的图片	非商业使用或教育目的
TREC	信息检索	多个主题，规模各异	研究用
SQuAD	自动问答	10w对"QA"	CC BY-SA 4.0
Europarl	机器翻译	多语种平行语料库，各有几十万句子	无版权限制

监督学习

- 数据集如果是带有标准答案的，这种机器学习方法称为“监督学习”。
- 监督学习方法让机器先做一遍题，然后和标准答案做比较，最后根据误差纠正模型的错误。
- 通常情况下，学习一遍的误差还是很大的，需要反复学习，反复调整。这个过程称为“迭代”。
- 在有标签的数据集上迭代学习的过程称为“训练”，训练用的数据集也叫“训练集”。训练的结果就是一系列的参数（特征权重）或模型。
- 利用训练好的模型，就可以计算任一姓名所对应的性别了，这个过程称为“预测”。

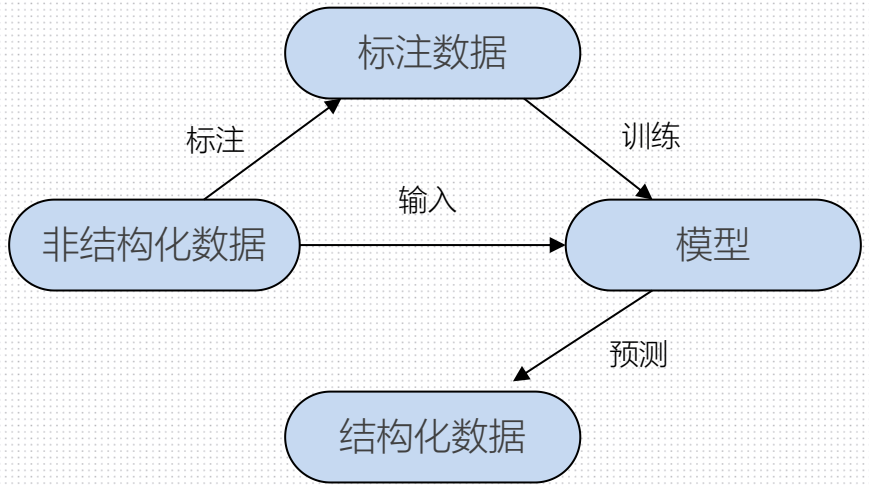
假设性别预测的模型是：

$$f(x) = \sum w_n \times x_n + b$$

训练集是：

```
[班尔达,1], [崔云龙,1], [陈萍,-1], [崔巍,1], [陈月会,1], [陈星星,-1], [陈贵香,-1], [陈莹,-1], [陈娇,-1], [陈婧怡,-1], [陈乐,1], [陈华星,1], [陈哲,1], [陈立,1], [陈佩珊,-1], [丁小燕,-1], [段青青,-1], [杜雷,1], [豆翠翠,-1], [段临晶,-1], [丁恒,1], ……
```

1. 初始可以随意随机给定w_n的值（-1~1之间）。
2. 针对训练集中的每一条入参数据，用当前模型去做预测。
3. 如果预测计算的结果是负数，但是实际答案是1，则可以调整$x_i = 1$的分项所对应的w_i，增大一些数值。（例如每次增加0.1）。反之，如果预测计算的结果是正数，但是实际答案是-1，则可以调低对应的w_i。
4. 用调整后的模型再去进行训练和预测。
5. 反复迭代之后，男性常用字的特征权重就会增大，女性常用字的特征权重就会减小，最终达到一个可以实用的数据模型。
6. 这样，需要的“权重优先级”自动求出来了。



（这就是后面会提到的感知机算法）

HUAWEI TECHNOLOGIES CO., LTD.
HUAWEI

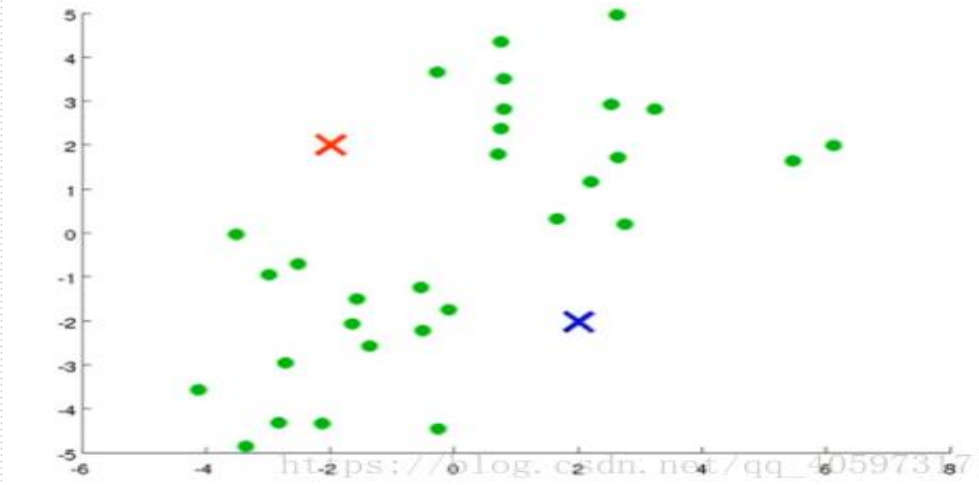
无监督学习

- 如果在机器学习的训练过程中，我们只给机器输入数据（比如只有人名），但是不给答案（没有性别）。机器还能学到知识吗?
- 没有答案的机器学习，称为"无监督学习"。无监督学习的数据集被称为无标注（unlabeled）数据集。
- 无监督学习一般用于聚类和降维。

聚类： *把数据集分成一个个的簇cluster*

[景艳玲, 王艳改, 张艳琳]，[蒋雅娜，胡雅佳]，[季成飞，戚鹏飞]，[李强，卢瑞强，周强]，[孟文君, 郭文娟, 申洪文]……

K-means算法（K均值算法）（后文P22详述）



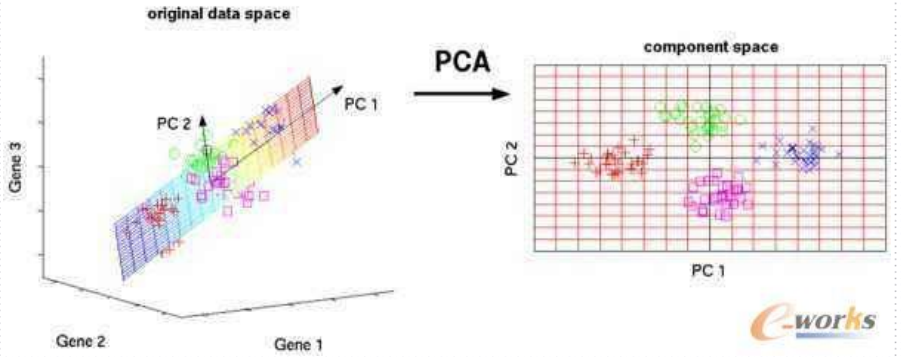
其他聚类算法：均值漂移、DBSCAN、GMM-EM、凝聚层次、图团体检测……

降维： *将样本点从高维空间变换到低维空间的过程*

$$f(x) = \sum w_n \times x_n + b$$

N个特征，则每一个数据用一个N维向量来表示，对应N+1维空间中的一个点。比如对于姓名的特征提取，如果以是否包含某个常用汉字做特征，则维度至少2000+。
降维的目的：1）对数据进行压缩，实现可视化；2）对学习算法进行加速。

主成分分析算法（PCA）



其他降维算法：Linear Discriminant Analysis、Locally linear embedding、Laplacian Eigenmaps……

HUAWEI

目 录

03

NLP的基本原理

HUAWEI

中文分词之词典分词

规则系统拆东墙补西墙，极其脆弱！

- 中文分词是指将一段中文文本拆分为一系列单词的过程。
- 词典分词是最简单、最常见的分词算法。一部词典（收录单词的列表）和一套查词典的算法规则即可。词典是静态、不完备的，然而还是可用的。（齐夫定律Zipf's law）

问题1：什么是单词？

吃饭
吃+饭
北京机场
北京+机场
……

工程角度：词典中有的就是单词，没有的就不是单词

希望	v	386
	n	96
稀罕	a	1
希冀	v	1
希腊	ns	19
希腊共和国	ns	1
……		

词典

问题2：怎么根据词典拆分文本？

拆分算法	例句	结果
完全切分	商品和服务	['商', '商品', '品', '和', '和服', '服', '服务', '务']
	就读北京大学	['就', '就读', '读', '北', '北京', '北京大学', '京', '大', '大学', '学']
正向最长匹配	就读北京大学	['就读', '北京大学']
	研究生命起源	['研究生', '命', '起源']
逆向最长匹配	研究生命起源	['研究', '生命', '起源']
	项目的研究	['项', '目的', '研究']

双向最长匹配

例句	正向最长匹配	逆向最长匹配
项目的研究	**['项目', '的', '研究']**	['项', '目的', '研究']
商品和服务	['商品', '和服', '务']	**['商品', '和', '服务']**
研究生命起源	['研究生', '命', '起源']	**['研究', '生命', '起源']**
当下雨天地面积水	**['当下', '雨天', '地面', '积水']**	['当', '下雨天', '地面', '积水']
结婚的和尚未结婚的	['结婚', '的', '和尚', '未', '结婚', '的']	**['结婚', '的', '和', '尚未', '结婚', '的']**
欢迎新老师生前来就餐	['欢迎', '新', '老师', '生前', '来', '就餐']	['欢', '迎新', '老', '师生', '前来', '就餐']

HUAWEI TECHNOLOGIES CO., LTD.
HUAWEI

信息抽取（1）

- **信息抽取**：是指从非结构化文本中提取结构化信息的任务。
- 三类技术：基于规则、监督学习、无监督学习。（从本节开始的任务以介绍无监督学习为主）
- 主要应用：新词提取、关键字提取、关键短语提取、关键句提取。（介绍前两种）

新词提取

新词：词典中没有的词，就是新词（OOV）。价值：减少修订维护词典的成本。（监督学习的语料标注成本太高）

问题：如何在无监督（不进行语料标注）的情况下，正确地识别和拆分出词语？具体来说，即给定一段文本，随机取其中一个片段，判断是否是一个词？而不是几个单字？

思想：

判断条件	举例	数学表达	公式
该片段其内部成分搭配比较固定，经常以固定组合形式出现。	蝴蝶、新冠	互信息（Mutual Information）	$I(X;Y)=\sum_{x,y}p(x,y)\log\frac{p(x,y)}{p(x)p(y)}$
该片段左右的搭配比较丰富，即该片段可以在句子中以独立形式自由出现。	蝴蝶[飞/效应/蜕变]、[喜欢/漂亮的]蝴蝶 新冠[传播/检测/病毒]、[抗击/感染/可怕的]新冠	信息熵（Entropy）	$H(X)=-\sum_{x}p(x)\log p(x)$
该片段在大量文本中出现的频率较高。		词频	

实现：

1. 喂给ML模块大量的没有任何标注的原始文本。
2. ML对原始文本进行全组合拆分提取（一般取2~4个字以内的组合）。
3. 对于所有候选片段，ML根据上面的计算公式来统计、计算和排序，互信息和信息熵越大的越靠前。
4. 挑选TOP词频的词语，再用旧词的词典进行一遍过滤，就可以得到新词列表。

HUAWEI TECHNOLOGIES CO., LTD.
HUAWEI

信息抽取（2）

关键字提取（提取文章中的重要核心词汇）：单文档**词频**统计法，多文档**词频-倒排文档频次TF-IDF** (Term Frequency – Inverse Document Frequency)统计法

词频统计法

理论依据：关键字通常在文章中反复出现，为了解释关键字，作者通常会反复提及。

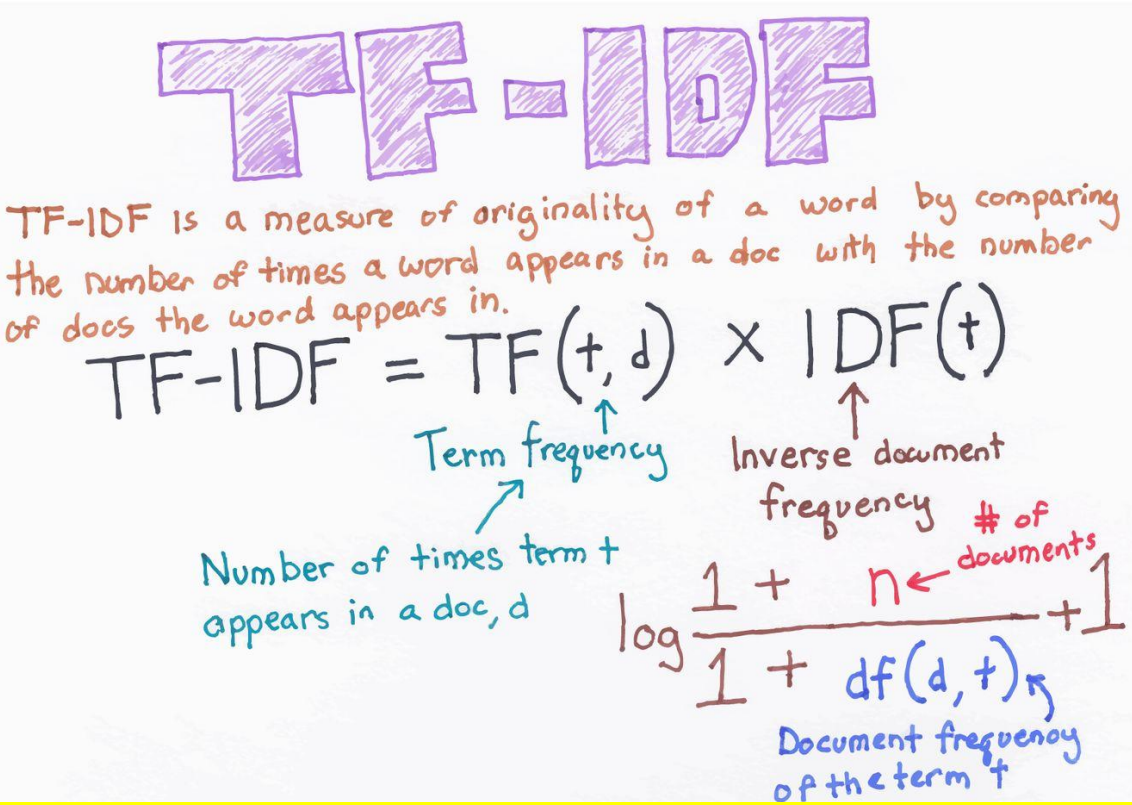
适用范围：单文档关键字提取。

技术方法：通过统计文章中每种词语的词频并排序，提取其中的高频词汇（排除停用词）作为关键字。

停用词（Stop Words）：不重要的意义不大的词语，例如助词（的、了、着、吧……）、连词、标点符号等。通常NLP中都会构建常见停用词表。

具体实现：

1. 输入单篇文章的完整文本。
2. ML对原始文本进行分词处理，具体方法同新词提取。
3. 对于所有词语进行词频统计和排序。
4. 使用停用词表对停用词进行过滤。
5. 按要求取前N个TOP词作为文档的关键字。

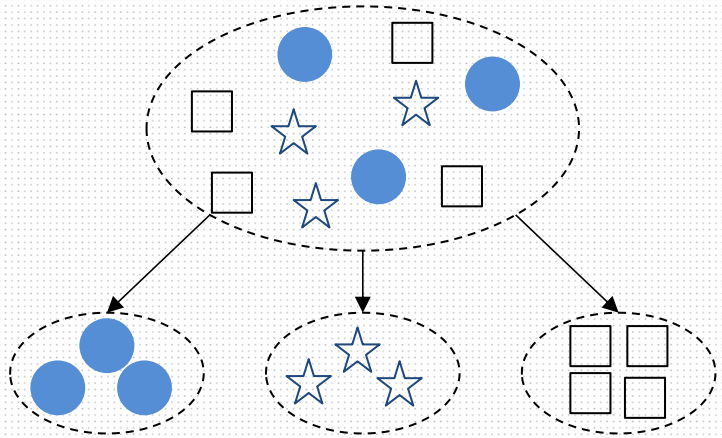


TF-IDF的理论依据：词频的依据同左。而在多文档中，一个词语对于当前文档的重要程度还反比与有多少文档包含它。（包含它的文档越多，越不能体现文档的特色）

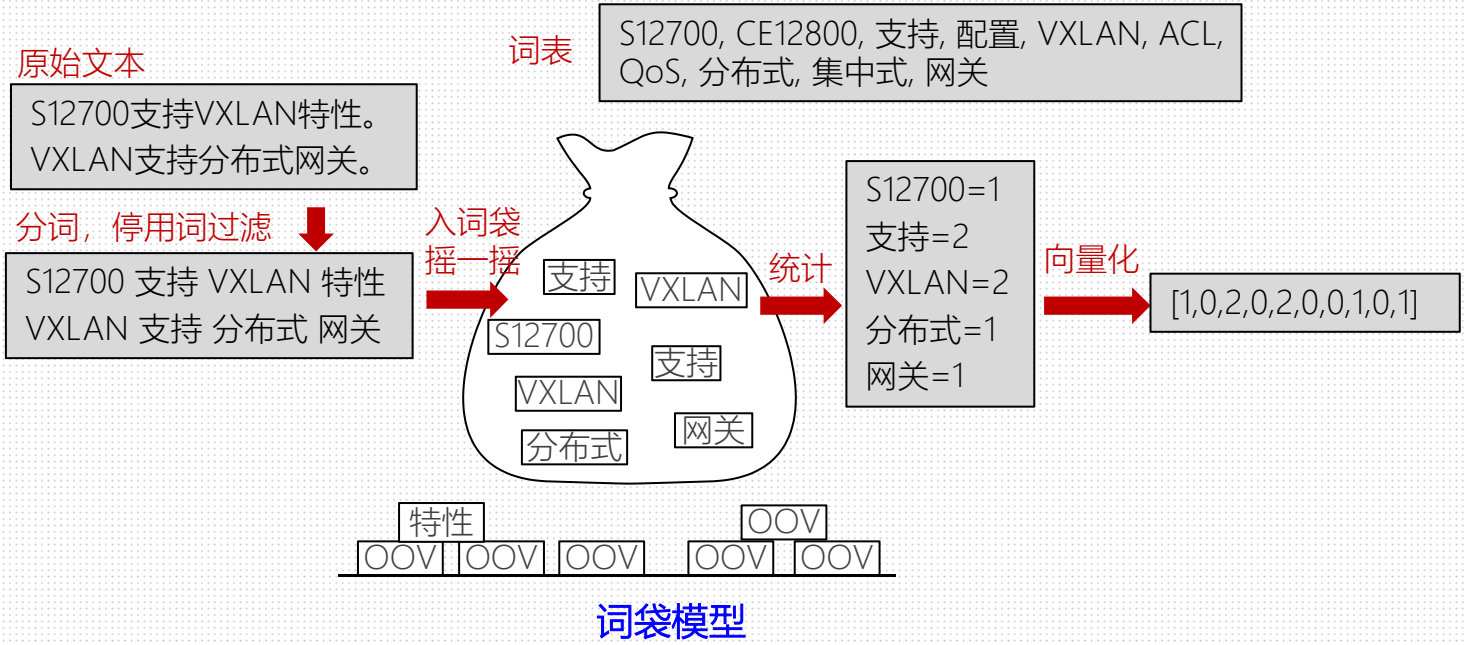
HUAWEI TECHNOLOGIES CO., LTD.

文本聚类（1）

- 聚类（clustering）：将给定对象划分为不同子集（称为簇cluster）的过程。通常用于数据的预处理或归档相似数据。
- 文本聚类（text clustering）：对文本进行聚类分析，广泛用于文本挖掘和信息检索（IR）领域，比如改善搜索结果，生成同义词等。在文本预处理中，聚类同样发挥作用，比如标注语料之前，需要从生语料中选取一定数量的代表性样本，则可以先进行文本聚类。
- 词袋模型（Bag of Words）：最常用的文本表示模型，将文本想象成一个装有单词的袋子，通过统计每个单词的特征值，来将文本转化成向量。词袋模型并不考虑词序和语义，所以“人吃鱼”和“鱼吃人”的词袋向量是完全一样的，但实际工程中词袋模型还是一个非常高效的模型。
- 词袋中的特征值统计方法：词频统计、布尔词频统计、TF-IDF统计、词向量统计（后面深度学习中会提到）。



聚类



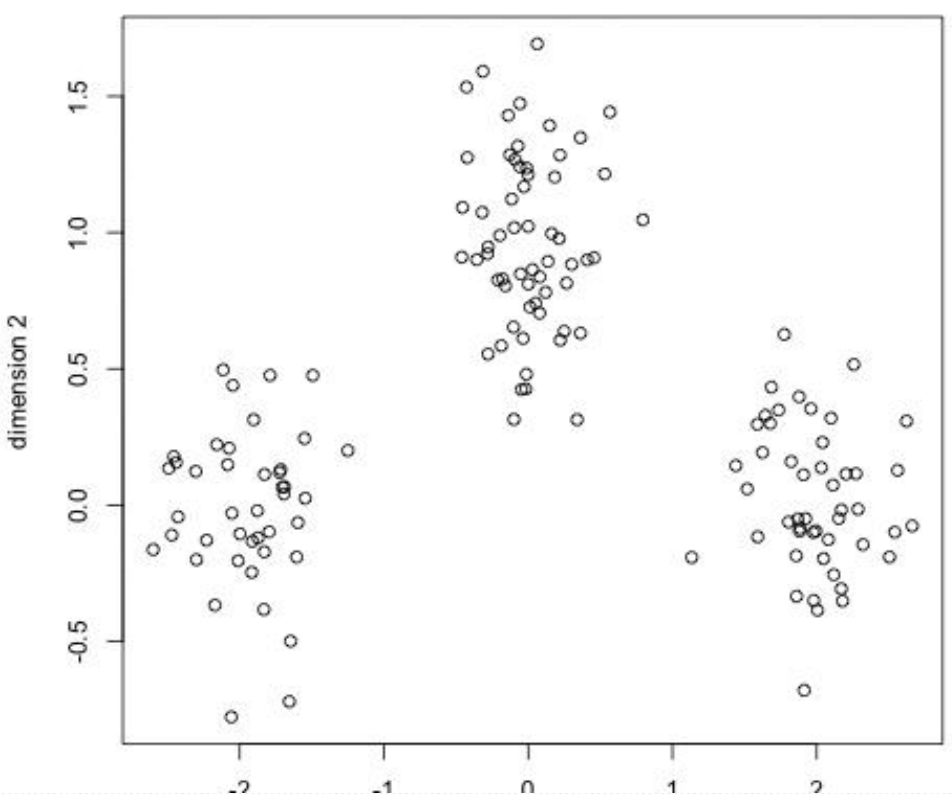
词袋模型

HUAWEI

文本聚类（2）

- 当文本都转化为向量之后，就可以用纯数学上的算法模型对其进行处理了。
- 对于数据聚类，最简单实用的聚类算法就是k均值算法（k-means）。
- 其他聚类算法：均值漂移、DBSCAN、GMM-EM、凝聚层次、图团体检测……

K均值算法示意图



K均值算法描述

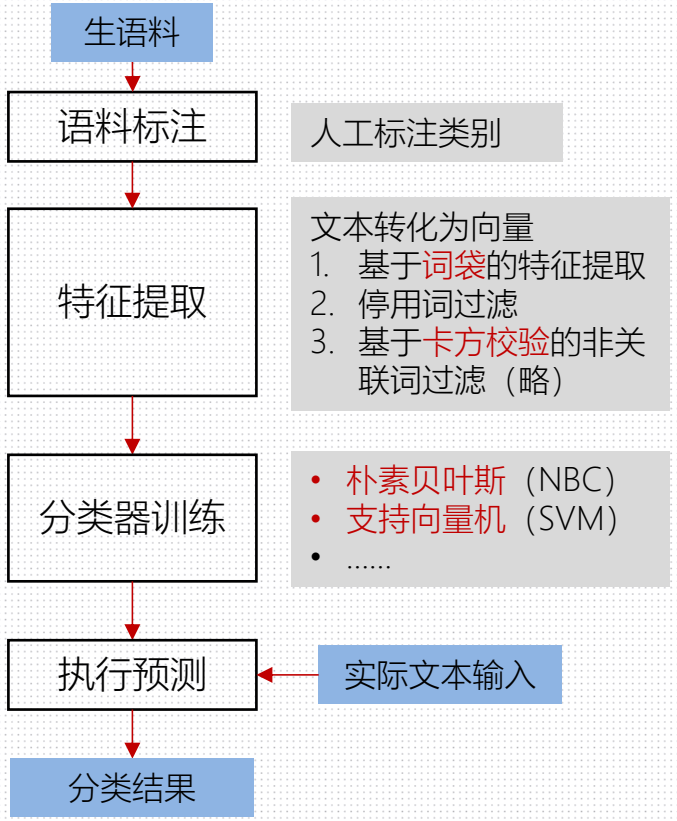
1. 确定需要聚类的簇数量K。
2. 将所有数据随机的划分到这些簇中。
3. 计算出每个簇的中心点（中心点是与每个数据点向量长度相同的位置）。
4. 再计算出全局每一个数据点到各个中心点的距离，数据点距离哪个中心点最近，就重新划分到这个类中。
5. 再重新计算每个簇的中心点，作为新的中心点。
6. 重复以上步骤，直到每一类中心在每次迭代后变化不大为止。也可以多次随机初始化中心点，然后选择运行结果最好的一个。

注：步骤2~4是可以颠倒的，也可以先随机选取K个点作为中心点，然后再根据步骤4进行数据点的划分，再重新计算中心点等步骤。

HUAWEI

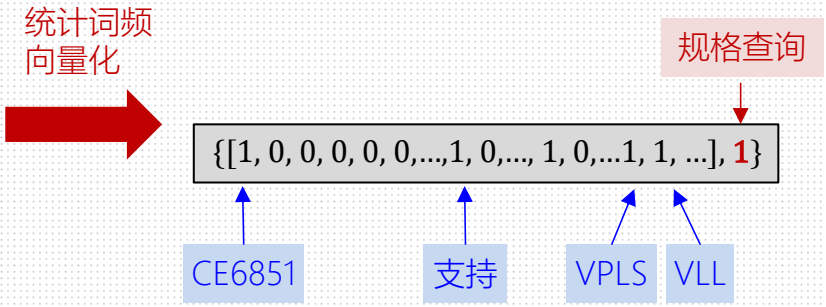
文本分类（1）

- 文本分类（text classification）：是指将一个文本归类到一个或多个类别中的NLP任务。所谓类别（category）又称为标签（label），所有类别可以组成一个标注集。标注集是确定的，则分类的结果也一定属于标注集，不会出现标注集之外的分类。
- 文本分类的应用场景非常广泛，意图识别、垃圾邮件过滤、垃圾评论过滤、自动标签、情感分析等等。
- 文本分类通常使用监督学习的模式。即需要对训练样本进行语料标注（只需要标注每份样本的类别即可）。



iKnow智能问答意图识别的训练样本标注

```
[CE6851HI是否支持VPLS/VLL,规格查询],
[CE6810EI ARP表规格,规格查询],
[CE7855EI是否支持堆叠,规格查询],
[WLAN推荐的版本,版本推荐],
[S系列和E系列交换机推荐的版本,版本推荐],
[CE系列交换机推荐的版本,版本推荐],
[5720默认密码,查询密码],
[防火墙缺省Web用户名和密码,查询密码],
[默认Telnet用户名和密码,查询密码],
[请问S5720-52X-PWR-SI-AC的功耗,查询功耗],
[s6720的功耗是多少,查询功耗],
[s5700的整机功耗,查询功耗],
[Web网管无法登录,故障处理],
[PPPoE拨号方式无法上网,故障处理],
[E1接口对接不能Up,故障处理],
[推荐几款园区交换机， 产品推荐],
[给我推荐几款FCoE交换机,产品推荐],
……
```



一个词一个维度（特征）

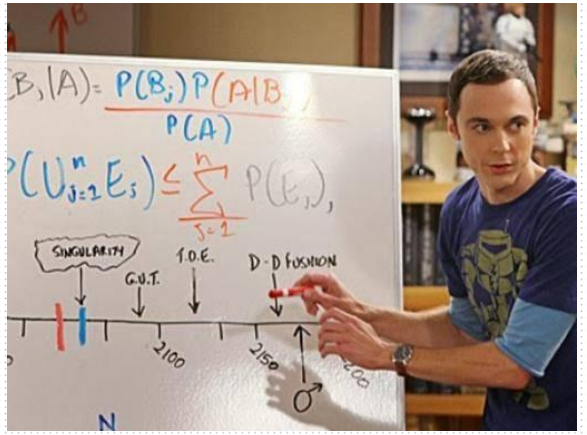
通过词袋模型统计每个样本中的词频

每个类别表示为一个数值

HUAWEI

文本分类（2）

- 当文本都转化为向量之后，就脱离语言、句子等现实世界的约束，进入机器学习的世界。
- 对于文本分类，最简单实用的分类算法是朴素贝叶斯分类器NBC（Naïve Bayes Classfier）
- 其他分类器算法：支持向量机SVM（Support Vector Machine）、决策树、逻辑回归算法（LR，Logistic Regress逻辑回归）、KNN(K-Nearest Neighbor，K 最近邻近)算法、ANN（Artificial Neural Network，人工神经网络）算法等



你必须了解的贝叶斯定理！

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

$P(A|B)$表示的是一种条件概率，即在B事件发生的情况下，A事件发生的概率。

变形式：$P(B|A) \cdot P(A) = P(A|B) \cdot P(B)$

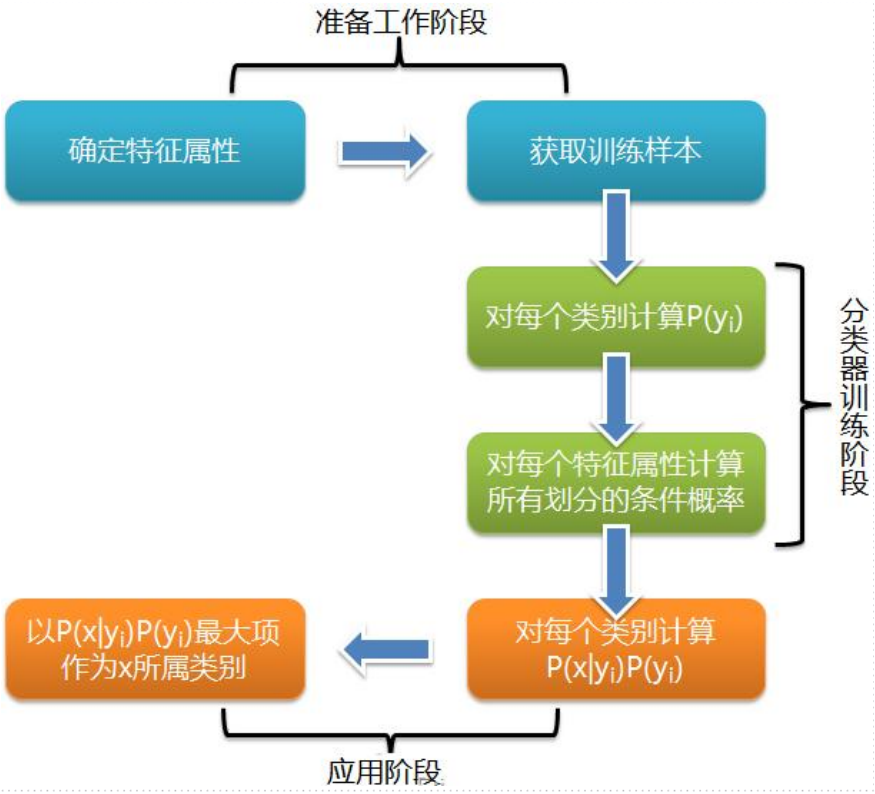
你在街上看到一个黑人，让你猜TA哪里来的，你会猜哪里？为什么？

$$P(\text{非洲}|\text{黑人}) = \frac{P(\text{黑人}|\text{非洲}) \cdot P(\text{非洲})}{P(\text{黑人})} = \frac{82.7\% \times 16.69\%}{18.05\%} = 76.5\%$$

$$P(\text{亚洲}|\text{黑人}) = \frac{P(\text{黑人}|\text{亚洲}) \cdot P(\text{亚洲})}{P(\text{黑人})} = \frac{2.32\% \times 54.36\%}{18.05\%} = 6.98\%$$

$$P(\text{欧洲}|\text{黑人}) = \frac{P(\text{黑人}|\text{欧洲}) \cdot P(\text{欧洲})}{P(\text{黑人})} = \frac{5.32\% \times 9.82\%}{18.05\%} = 2.89\%$$

贝叶斯定理体现的核心思想是，当我们无法准确获知事物的本质时，可以依靠与该事物关联的事件出现的多少，来判断其本质属性的概率。



HUAWEI TECHNOLOGIES CO., LTD.

目 录

04

深度学习与NLP

HUAWEI

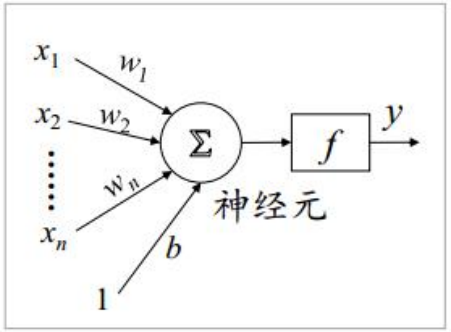
再看深度学习和神经网络

深度学习就是采用**多层**神经网络算法模型的一种机器学习方法。

两句话回顾感知机迭代算法

(1) 读入训练样本$(x^{(i)}, y^{(i)})$，执行预测$\hat{y} = sign(w \cdot x^{(i)})$。
(2) 如果$\hat{y} \neq y^{(i)}$，则更新参数$w \leftarrow w + y^{(i)}x^{(i)}$。

一个感知机加上一个激活函数（也叫传递函数）构成了一个神经元



$\boldsymbol{x_1}$ ~ $\boldsymbol{x_n}$ 为输入向量的各分量。

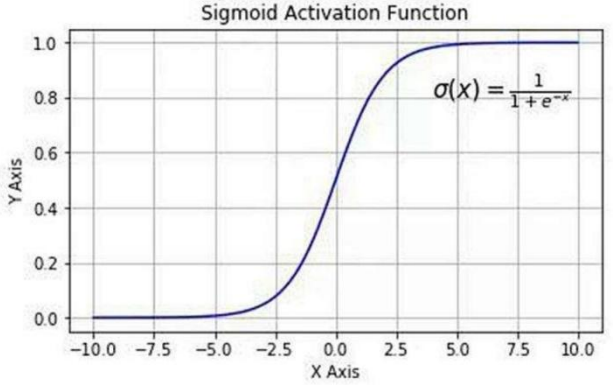
$\boldsymbol{w_1}$ ~ $\boldsymbol{w_n}$ 为权值系数。

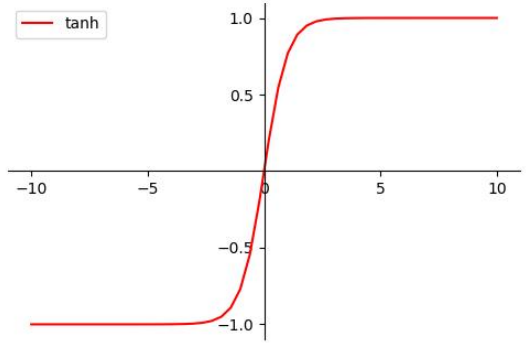
$\boldsymbol{b}$为偏置系数。

$\boldsymbol{f}$为非线性传递/激活函数，例如$\boldsymbol{f(x)} = \frac{1}{1+e^{-x}}$

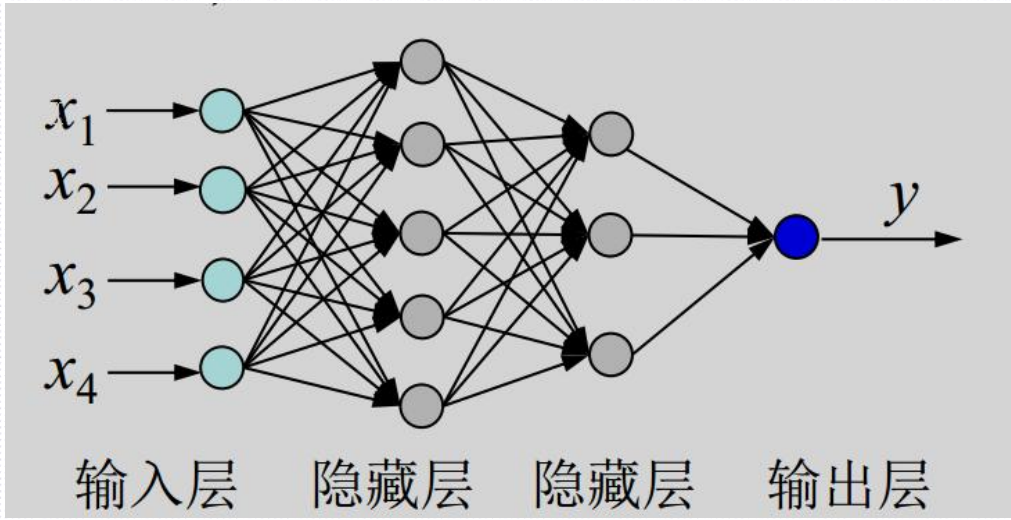
神经元的输出：$\boldsymbol{y = f(\sum w_n \times x_n + b)}$

激活函数模拟神经元的受激时的非线性反应表现（σ函数或tanh函数）





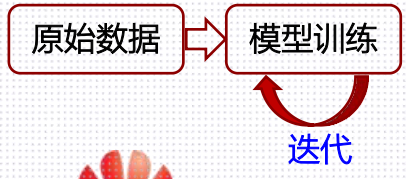
多层/多个神经元全连接，构成神经网络



深度学习相比传统NLP方法的优势

- 用稠密向量解决数据稀疏问题
- 用多层网络自动提取特征表示
- 端到端完成完整的应用





HUAWEI

Word2Vec

- 2013，Google，Word2Vec
- 核心概念：词向量（Word Vector），用来对词语特征（也可以叫维度或属性）进行形式化表达的数学向量形式。

独热码

10000个词的词表
[阿，爱，……，智能，职业]

One-Hot向量表示：

阿：[1,0,0,0,……,0]
爱：[0,1,0,0,……,0]
……
职业：[0,0,0,0,……,1]

数据稀疏
无相关性

词向量

维度	国王	皇后	苹果	酒店
是否是男性	0.98	0.02	0.15	0.3
是否是女性	0	0.99	0.27	0.2
是否是水果	0.03	0.07	0.97	0
是否是产品	0.11	0.12	0.89	0.23
是否是地址	0.07	0.28	0.04	0.99
…	…	…	…	…

国王：[0.98, 0, 0.03, 0.11, 0.07, …]

皇后：[0.02, 0.99, 0.07, 0.12, 0.28, …]

苹果：[0.15, 0.27, 0.97, 0.89, 0.04, …]

酒店：[0.3, 0.2, 0, 0.23, 0.99, …]

…….

问题1：维度怎么定义？⇨ 无法定义 ⇨ 深度学习

问题2：构建什么样的模型，来学习词向量？

一个词的意思，应该由和它一起出现的周围的词（上下文）来表现

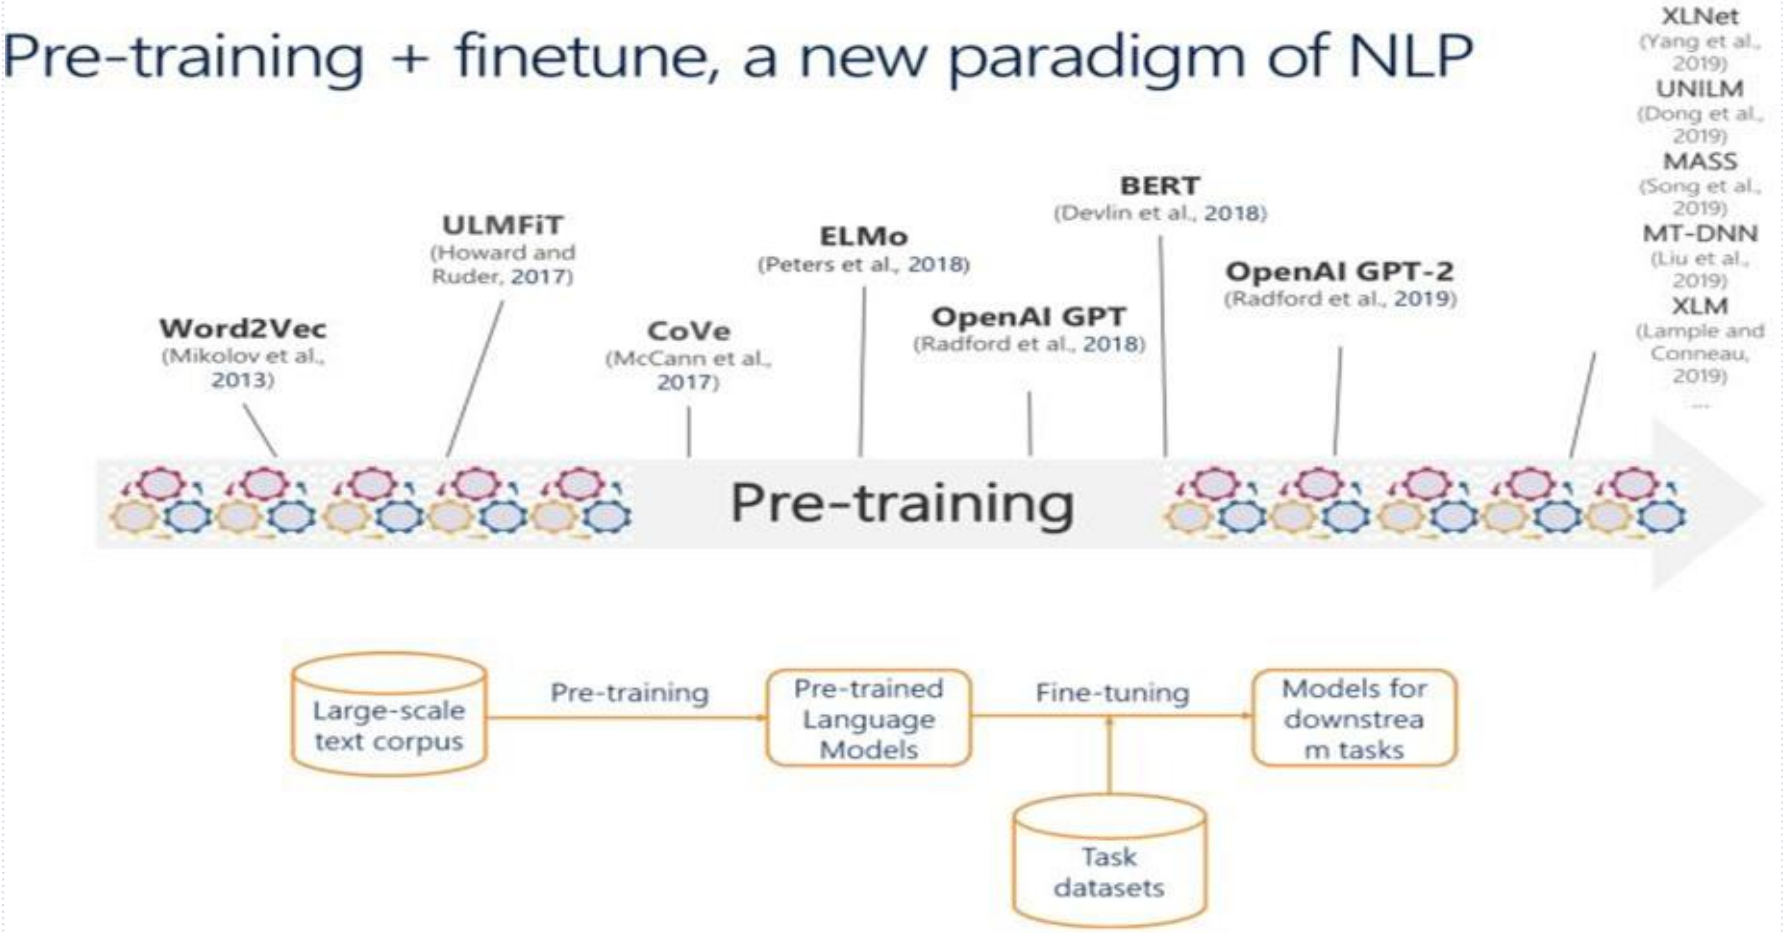
两个不同思路的模型：

- CBOW（Continuous Bag of Words）：输入上下文的词，预测中心词是什么
- SG（Skip-Gram）：输入中心词，预测上下文长什么样

HUAWEI

各类新技术概览

自从Word2Vec之后，许多NLP学者发现，只要将原来稀疏的特征向量（独热码），替换类似于词向量一样的稠密向量，用神经网络就可以得到更好的性能。所以基于深度学习的NLP训练的模型和方法不断涌现。 ELMo、GTP、BERT、XLNET.....
总体上，NLP已经从过去的特征工程转变为结构工程。



HUAWEI

目 录

05

NLP的主要应用

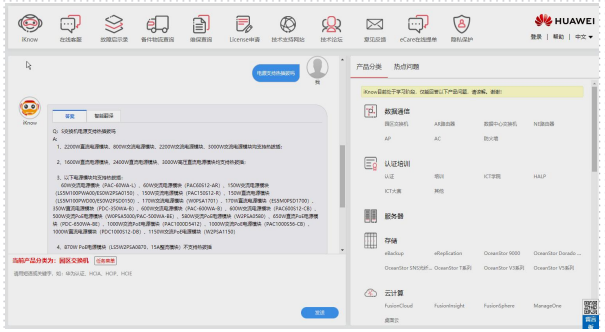
HUAWEI

NLP的主要应用（1）



智能搜索

Item内容理解、Query理解、检索召回相似文档、text2sql 等



智能问答

用户Query分词、意图识别、实体识别、答案召回。



翻译智能

通过文本语言分析，精准翻译语句内容，从而帮助用户跨语言沟通。



舆情分析

信息抽取、文本聚类，挖掘突发事件、舆论导向。多维度分析情绪、热点、趋势、传播途径等。



内容推荐

信息抽取、句法分析、语义分析，精准匹配出语义相似的内容，从而快速构建内容推荐场景。



内容风控

聊天室广告屏蔽，黄赌毒内容审核，脏话过滤；

NLP的主要应用（2）



信息抽取整理

各种UGC内容tag提取，主题分布按主题归档，政策惩罚抽取，法律判决抽取，公司主权结构抽取等；



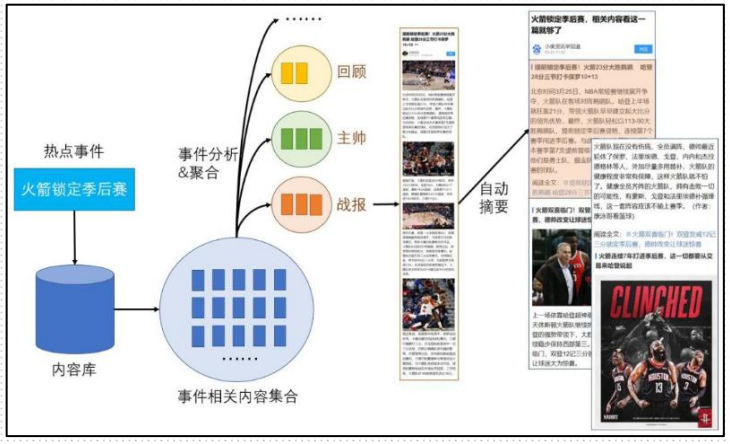
推理预测

法律罪行推断，疾病并发症推断，商业事理推断；购买预测，点击预测，热点预测，爆款预测，疾病预测。



语音&图像文字识别

对于单纯的语音和图像转文字，则利用NLP可以实现对于识别结果的文本纠错等



自动内容写作

辅助新闻写作，广告文案生成……

目 录

06

参考资源

HUAWEI

常用的开源NLP工具包

工具包	介绍	主体语言
NLTK	NLTK 最知名的NLP工具，来自宾夕法尼亚大学，以研究和教学为目的而生。NLTK主要面向英文，但它很多NLP模型与语言无关，可复用。	Python
jieba	一款非常流行中文开源分词包，具有高性能、准确率、可扩展性等特点	Python
OpenNLP	Apache的基于机器学习的NLP工具包。它支持最常见的NLP任务，如断词，句子切分，部分词性标注，命名实体提取，分块，解析和指代消解。	Java
FudanNLP	复旦大学一套中文NLP工具包，包括中文分词、词性标注、命名实体识别、依存句法分析、关键词抽取、时间短语识别、文本分类、新闻聚类等功能。	Java
Stanford CoreNLP	斯坦福大学NLP工具包，包含 53 种语言预训练模型，支持多种语言的完整文本分析管道，包括分词、词性标注、词形归并和依存关系解析功能等。	Python、Java
THUCTC	清华大学推出的中文文本分类工具包，能够自动高效地实现用户自定义的文本分类语料的训练、评测、分类功能。	Java
textsum	谷歌的开源TensorFlow版本的摘要生成程序。textsum的核心模型就是基于注意力的模型，textsum使用了LSTM和深度双向RNN。	Python
NLPIR	中科院张华平博士的中文分词工具包，中文分词；英文分词；词性标注；命名实体识别；新词识别；关键词提取	Python、Java
snownlp	SnowNLP是一个处理中文的NLP类库，受到TextBlob的启发而开发，这里没有用NLTK，所有的算法都是自己实现的，并且自带了一些训练好的字典。	Python
HanLP	初学者入门学习较好的一款通用NLP开源程序包，作者何晗。	Python、Java
AllenNLP	Allen AI实验室的作品，采用深度学习技术，基于PyTorch开发。	Python

HUAWEI

Thank you

www.huawei.com

Copyright©2015 Huawei Technologies Co., Ltd. All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.